Aprimoramento de Enlaces de Comunicação Óptica em Espaço Livre com Feixes Vetoriais Estruturados e Redes Neurais Informadas pela Física

Fábio Augusto Pereira, Luciano Leonel Mendes, Felipe Augusto Pereira de Figueiredo
Programa de Pós-Graduação em Telecomunicações
INATEL
e-mail: fabio.pereira@mtel.inatel.br

***Abstract*—Free-space optical (FSO) communication is a promising alternative for high-capacity wireless links, although its performance can be affected by atmospheric turbulence, beam spreading, and fluctuations in received optical power. Structured vector beams, whose spatial and polarization degrees of freedom can be jointly controlled, offer opportunities for encoding and transmitting information through optical channels. In parallel, Physics-Informed Machine Learning (PIML), particularly Physics-Informed Neural Networks (PINNs), incorporates physical laws into the training process and may improve the consistency of data-driven models under limited observations. This paper presents a simulation methodology for investigating the use of a PINN in an FSO link employing structured vector beams. A propagation distance of 270 m is considered, with atmospheric turbulence represented by a stochastic channel model. The proposed evaluation compares a physical numerical reference, a conventional neural network, and a PINN using field reconstruction error and communication-oriented metrics. Since the source documents do not provide completed simulation outputs, numerical results are not asserted here; the experimental section defines the procedure and the results section specifies the measurements required for quantitative validation.**

***Index Terms*—Free-space optical communication, structured light, vector beams, atmospheric turbulence, physics-informed machine learning, physics-informed neural networks.**

I. Introdução

A demanda por enlaces de comunicação com elevada capacidade de transmissão tem motivado o estudo de tecnologias ópticas sem fio. A comunicação óptica em espaço livre (Free-Space Optical Communication – FSO) utiliza a propagação da luz pelo espaço livre para transportar informação, oferecendo potencial para altas taxas de transmissão e implantação flexível. Entretanto, o desempenho do enlace pode ser degradado por turbulência atmosférica, espalhamento do feixe, desalinhamento e flutuações na potência recebida.

A luz estruturada amplia as possibilidades de controle dos campos ópticos por meio da manipulação de graus de liberdade espaciais e de polarização. Feixes vetoriais, em particular, apresentam distribuições de polarização espacialmente dependentes e podem ser considerados em arquiteturas de comunicação óptica que exploram mais de um grau de liberdade do campo [1].

Paralelamente, técnicas de aprendizado de máquina vêm sendo investigadas para modelagem e compensação de canais complexos. Uma limitação dos modelos puramente orientados por dados é a dependência de amostras de treinamento representativas. O aprendizado de máquina informado pela física (Physics-Informed Machine Learning – PIML) procura reduzir essa limitação incorporando equações e restrições físicas ao processo de treinamento [2].

Este trabalho propõe uma metodologia de simulação para investigar o uso de uma rede neural informada pela física na modelagem e recuperação de campos em um enlace FSO com feixes vetoriais estruturados. O foco é definir uma comparação reproduzível entre um modelo físico de referência, uma rede neural convencional e uma Physics-Informed Neural Network (PINN), sem atribuir resultados numéricos que ainda não tenham sido obtidos por execução experimental.

II. Comunicação Óptica em Espaço Livre e Luz Estruturada

A. Fundamentos de FSO

Um enlace FSO transmite informação por meio de um feixe óptico que se propaga em um meio não guiado. Em comparação com enlaces ópticos confinados em fibra, o canal FSO está diretamente sujeito às condições do ambiente de propagação. Variações do índice de refração do ar podem modificar a fase e a distribuição espacial do campo, enquanto a divergência do feixe e as perdas de acoplamento afetam a potência recebida.

Em uma avaliação de desempenho, é importante separar a degradação óptica da degradação da informação recuperada. Métricas como erro de reconstrução do campo descrevem a fidelidade física do modelo, enquanto a taxa de erro de bit (Bit Error Rate – BER), a relação sinal-ruído e a taxa de símbolos corretamente detectados caracterizam o enlace de comunicação.

B. Propagação óptica e turbulência atmosférica

A propagação de um campo óptico monocromático pode ser descrita, sob hipóteses apropriadas, pela equação de Helmholtz:

$$\nabla^2 U(\mathbf{r}) + k^2 n^2(\mathbf{r}) U(\mathbf{r}) = 0, \tag{1}$$

em que $U(\mathbf{r})$ representa o campo complexo, $k = 2\pi/\lambda$ é o número de onda, λ é o comprimento de onda e $n(\mathbf{r})$ é o índice de refração do meio.

Sob a aproximação paraxial, a propagação pode ser modelada por uma equação de evolução transversal. Uma forma simplificada, para um campo escalar e um meio de referência homogêneo, é

$$\frac{\partial U(x,y,z)}{\partial z} = \frac{i}{2k}\nabla_{\perp}^{2} U(x,y,z), \tag{2}$$

na qual $\nabla_{\perp}^{2}$ é o Laplaciano transversal. Em um canal turbulento, as flutuações do índice de refração introduzem perturbações adicionais na fase e na amplitude do campo. A implementação numérica deve declarar explicitamente o modelo de turbulência e os parâmetros empregados.

C. Feixes vetoriais estruturados

A luz estruturada compreende campos ópticos preparados com propriedades espaciais, temporais, espectrais ou de polarização controladas. Nos feixes vetoriais, a polarização varia espacialmente ao longo da seção transversal do feixe. Essa característica permite representar o campo como uma combinação de componentes ortogonais, cada uma associada a uma distribuição espacial e a um estado de polarização.

Uma representação geral do campo vetorial transversal pode ser escrita como

$$\mathbf{E}(x,y,z) = E_x(x,y,z)\,\hat{\mathbf{x}} + E_y(x,y,z)\,\hat{\mathbf{y}}, \tag{3}$$

em que E_x e E_y são componentes complexas ortogonais. Feixes de Laguerre–Gaussian podem ser usados como base espacial em uma implementação, desde que os índices modais, a cintura do feixe, o comprimento de onda e a normalização sejam especificados. A referência sobre luz estruturada destaca a relevância do controle de graus de liberdade ópticos e suas possibilidades de aplicação, incluindo comunicações [1].

III. Physics-Informed Machine Learning

A. Conceito

O Physics-Informed Machine Learning combina dados com conhecimento físico explícito. Em uma rede neural informada pela física, a função de custo pode incluir não apenas a diferença entre previsões e amostras conhecidas, mas também penalidades associadas à violação de equações diferenciais, condições iniciais e condições de contorno [2]. A diferenciação automática permite calcular derivadas da saída da rede em relação às coordenadas de entrada e formar os resíduos das equações físicas.

B. Função de perda da PINN

Considere uma rede neural que estima o campo complexo por meio de duas saídas reais, correspondentes às partes real e imaginária. Uma função de perda genérica pode ser definida por

$$\mathcal{L} = \lambda_d \mathcal{L}_{\text{dados}} + \lambda_p \mathcal{L}_{\text{fis}} + \lambda_b \mathcal{L}_{\text{contorno}}, \tag{4}$$

em que $\mathcal{L}_{\text{dados}}$ quantifica o erro em pontos conhecidos, $\mathcal{L}_{\text{fis}}$ penaliza o resíduo da equação de propagação e $\mathcal{L}_{\text{contorno}}$ representa as condições de contorno ou de entrada. Os coeficientes λ_d, λ_p e λ_b controlam a contribuição relativa de cada termo.

Para a equação paraxial apresentada em (2), pode-se definir o resíduo físico como

$$r(x,y,z) = \frac{\partial U_\theta}{\partial z} - \frac{i}{2k}\nabla_{\perp}^{2} U_\theta, \tag{5}$$

em que U_θ é a aproximação fornecida pela rede com parâmetros θ. Uma forma possível da perda física é a média de $|r(x,y,z)|^2$ nos pontos de colocação. Para modelar turbulência, o resíduo deve ser ajustado à equação e às hipóteses efetivamente implementadas no simulador; nota-se que a aplicação da equação de meio homogêneo não deve ocorrer como se ela descrevesse integralmente um canal turbulento.

C. Aplicação ao enlace FSO

Neste estudo, a PINN é considerada como um modelo de reconstrução ou estimação do campo óptico ao longo do enlace. Sua vantagem potencial é incorporar restrições de propagação ao treinamento. Contudo, a consistência física, por si só, não demonstra melhoria na comunicação digital. Para sustentar essa conclusão, é necessário também mapear o campo recebido para os símbolos transmitidos e medir métricas como BER, erro de símbolo ou fidelidade da recuperação.

IV. Experimento

A. Cenário de simulação

Propõe-se um enlace FSO com distância de propagação de $270\,\mathrm{m}$. O transmissor gera um feixe vetorial estruturado representado por componentes de campo ortogonais. A propagação é simulada numericamente e a turbulência atmosférica é introduzida por meio de uma realização estocástica do canal. A implementação deve registrar, no mínimo, o comprimento de onda, os parâmetros modais do feixe, a resolução espacial, o passo de propagação, a intensidade de turbulência e o número de realizações independentes.

Ainda está em fase de busca de resultados, a simulação realizada até o momento buscou analisar o impacto e realizar a comparação de comportamento do canal transmitinho com e sem a implementação do PINN

V. Resultados e Discussão

Nesta seção dicutiremos os resultados alcançados, inicialmente a técnica se mostra promissora e estima-se que o documento final trará uma análise mais detalhada da inclusão do PINN no canal de transmissão. As figuras abaixo representam algumas simulações já realizadas e os resultados obtidos.

A hipótese a investigar é que a inclusão de restrições físicas possa melhorar a coerência da reconstrução em regiões com poucas amostras ou em condições do canal pouco representadas no treinamento.

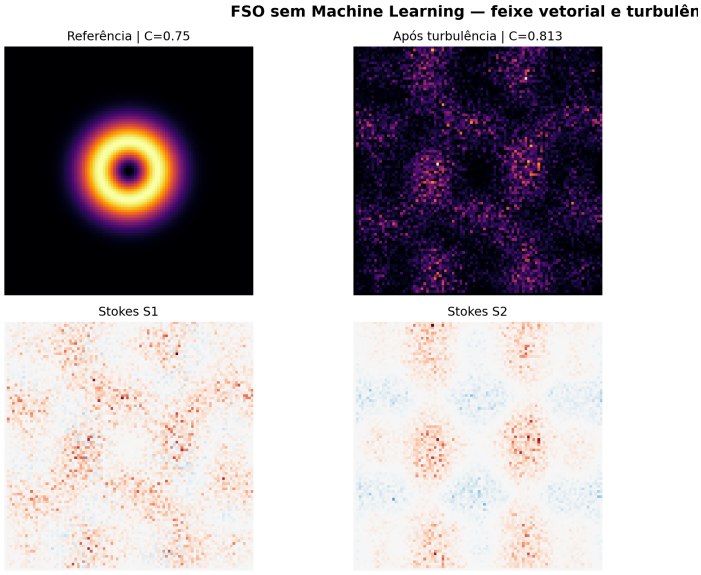


Figure 1. Análise dos feixes, da turbulência e do sinal recuperado

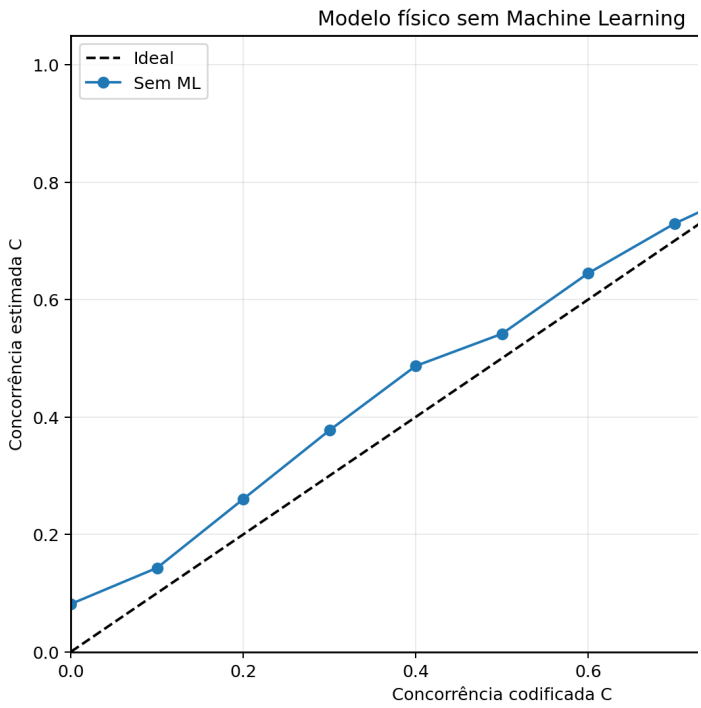


Figure 2. Análise do parâmetro de concorrência aplicadas no treinamento

Table I
TABELA PARA PREENCHIMENTO APÓS A EXECUÇÃO DAS SIMULAÇÕES.

Métrica	Referência	RNA	PINN
NMSE do campo	–	A calcular	A calcular
Erro de fase	–	A calcular	A calcular
Tempo de inferência	–	A calcular	A calcular
BER (se aplicável)	A calcular	A calcular	A calcular

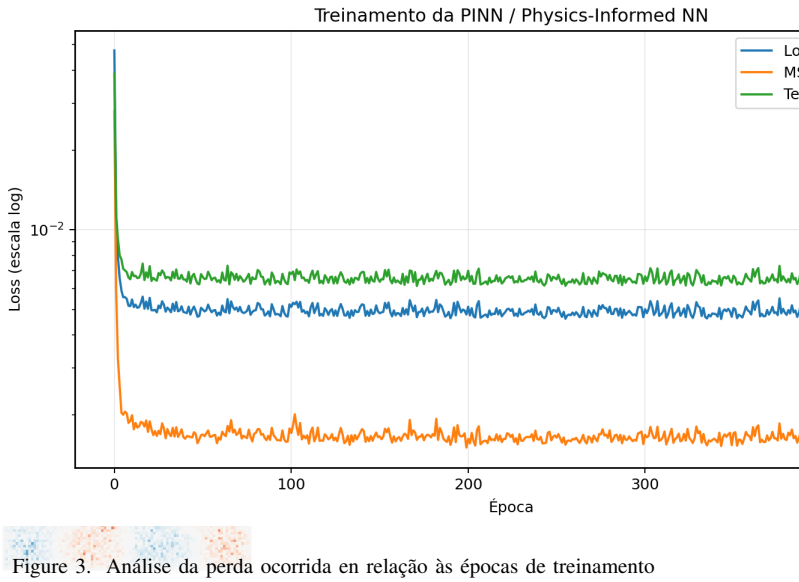


Figure 3. Análise da perda ocorrida en relação às épocas de treinamento

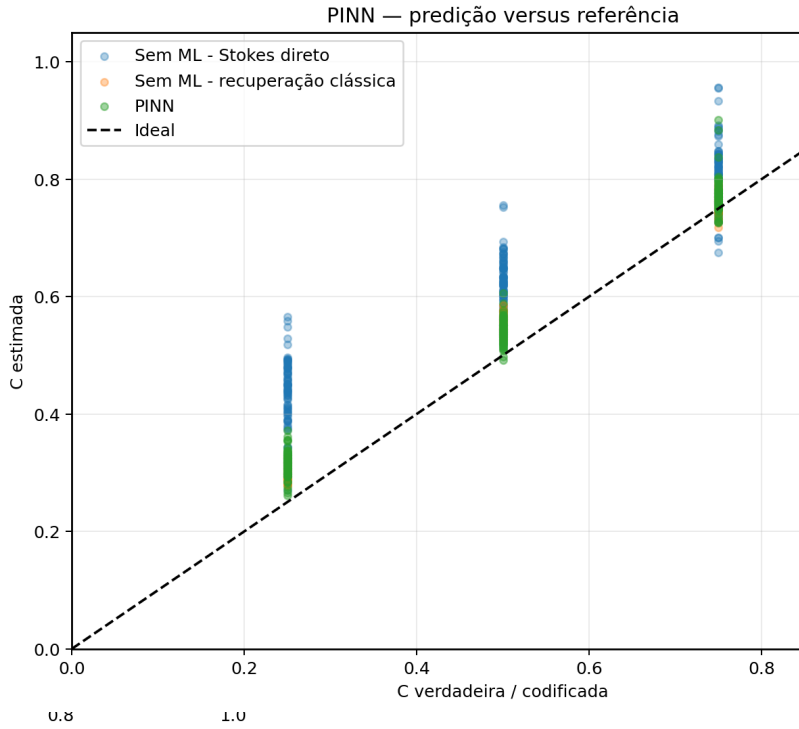


Figure 4. Análise predição

VI. CONCLUSÃO

Este trabalho apresentou uma metodologia para avaliar o uso de Physics-Informed Machine Learning em um enlace FSO com feixes vetoriais estruturados. A proposta combina a representação vetorial do campo óptico, um modelo numérico de propagação com turbulência atmosférica e uma PINN treinada com dados e restrições físicas. Foi definido um cenário de simulação de 270 m

A principal contribuição, nesta etapa, é a definição de um protocolo de avaliação reproduzível e de métricas que

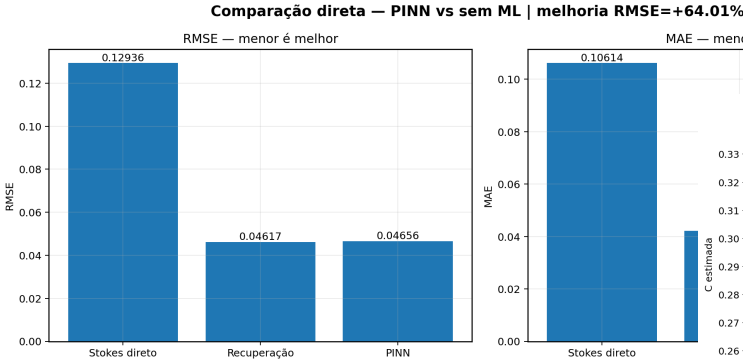


Figure 5. Análise comparativa erro quadrático médio

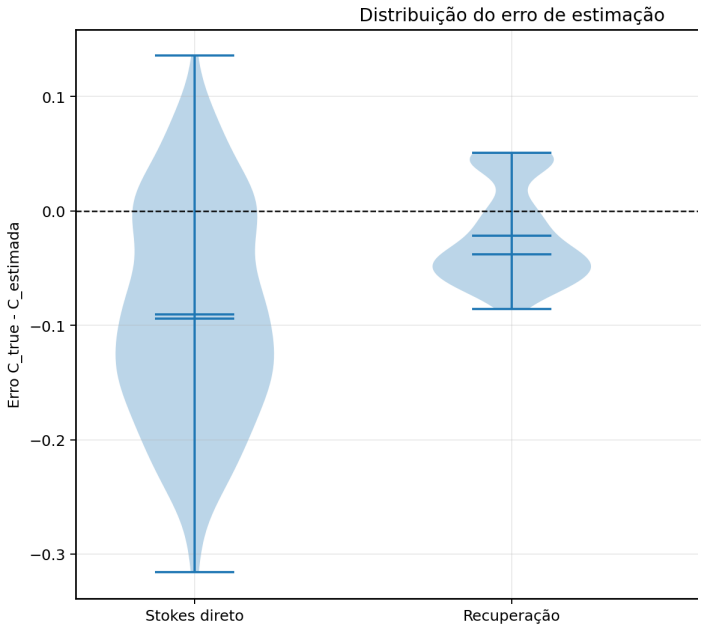


Figure 6. análise erro estimado

distinguem fidelidade física de desempenho de comunicação.

REFERENCES

[1] A. Forbes, M. de Oliveira, and M. R. Dennis, "Structured light," *Nature Photonics*, vol. 15, pp. 253–262, 2021, doi: 10.1038/s41566-021-00780-4.

[2] Z. Hao *et al.*, "Physics-Informed Machine Learning: A Survey on Problems, Methods and Applications," arXiv:2211.08064, 2022.

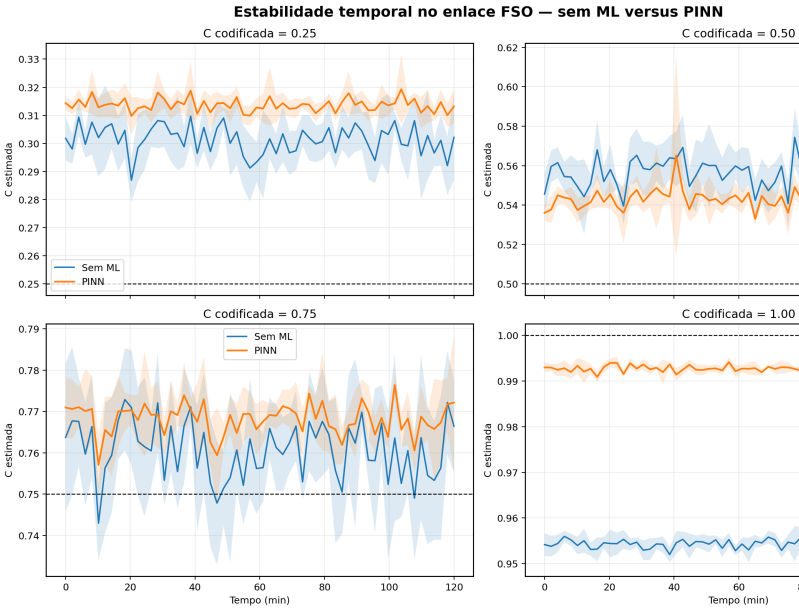


Figure 7. Análise estabilidade do link durante a transmissão

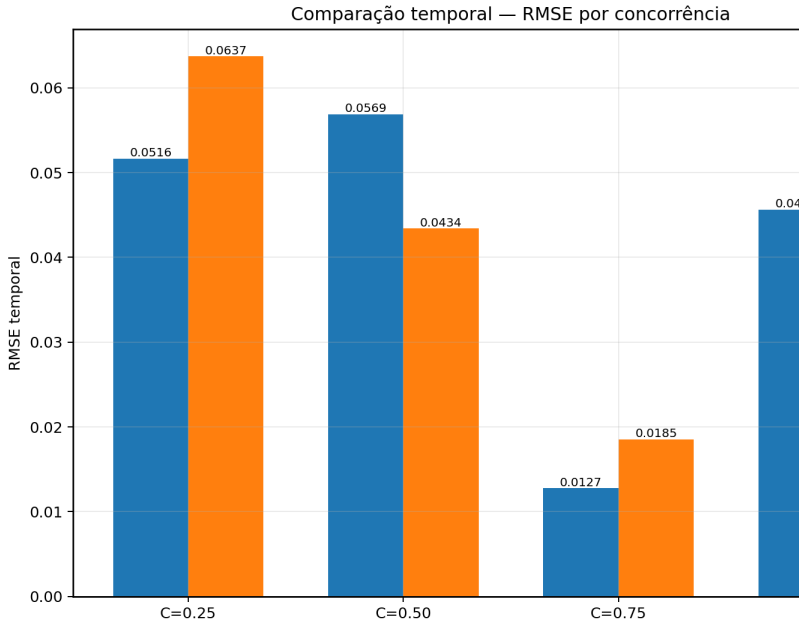


Figure 8. Análise comparativa temporal do erro quadrático