Proposta de Projeto Final — TP558

Estimação Robusta da Concorrência de Feixes Vetoriais em Canais Atmosféricos com Aprendizado de Máquina Physics-Informed

Fábio Augusto Pereira · 934

Disciplina: TP558 — Tópicos Avançados em Machine Learning

1. PROBLEMA GERAL DA ÁREA DO ESTUDO

A comunicação óptica no espaço livre (*free-space optical*, FSO) representa uma das fronteiras mais promissoras para o aumento de capacidade em redes de telecomunicações. Feixes estruturados que carregam *momento angular orbital* (OAM) permitem multiplexar múltiplos canais ortogonais, ampliando significativamente a taxa de transmissão por enlace [1]. Em particular, feixes *vetoriais*, cuja polarização varia espacialmente de forma não homogênea, introduzem um grau de liberdade adicional — a não-separabilidade entre os graus de polarização e espacial — que pode ser quantificado pela *concorrência* $C \in [0, 1]$ [2].

Um resultado recente e fundamental de Peters et al. (2023) [2] demonstrou experimentalmente, em um enlace real de 270 m, que a concorrência é *invariante* sob a ação da turbulência atmosférica — ainda que amplitude e estrutura de polarização sejam severamente distorcidas. Esse resultado decorre da natureza unitária do canal atmosférico e abre caminho para sistemas de comunicação FSO que exploram a não-separabilidade como recurso robusto. Contudo, imperfeições práticas do sistema receptor — ruído de câmera, desalinhamento de apontamento, absorção parcial por aerossóis e *crosstalk* do divisor de feixe polarizador (PBS) — introduzem erros sistemáticos na estimação de C via parâmetros de Stokes, comprometendo a robustez desse invariante em condições reais.

2. RELEVÂNCIA E MOTIVAÇÃO

A demanda global por largura de banda continua crescendo a taxas superiores à capacidade das redes ópticas convencionais. Enlaces FSO com modos estruturados oferecem uma rota de expansão compatível com a infraestrutura existente, sendo especialmente relevantes para a conectividade em zonas rurais e países em desenvolvimento [1]. A invariância da concorrência em canais turbulentos representa um ativo prático concreto: ao contrário da amplitude ou da fase do feixe — que demandam óptica adaptativa complexa —, C poderia ser lido diretamente no receptor sem correção de frente de onda, desde que sua estimação seja precisa o suficiente.

A estimação de C depende da integração dos parâmetros de Stokes sobre todo o perfil do feixe (Eq. 5 de [2]). Essa integral é sensível às distorções mencionadas acima. Técnicas de aprendizado de máquina que incorporam restrições físicas (*physics-informed machine learning*, PIML) oferecem uma abordagem promissora: ao incluir a invariância de C como regularizador durante o treinamento, o modelo pode aprender a

compensar artefatos de medição sem requerer pares de dados perfeitamente limpos — um cenário improvável em experimentos de campo.

3. OBJETIVO DA PESQUISA

O objetivo deste projeto é propor, treinar e avaliar um estimador de concorrência baseado em aprendizado de máquina physics-informed que supere o estimador de Stokes clássico em canais FSO realistas, quantificando a melhoria de acurácia em função do nível de turbulência, do tipo de ruído de câmera e da intensidade de absorção por aerossóis.

4. DESCRIÇÃO DO PROBLEMA E HIPÓTESE

Dado um feixe vetorial com concorrência codificada $C^* \in \{0{,}25;\ 0{,}50;\ 0{,}75;\ 1{,}00\}$, transmitido por um canal de 270 m com turbulência Kolmogorov (parâmetro de Fried r_0 variável) e recebido com imperfeições de hardware, define-se o problema de estimação:

Encontrar um mapeamento $f: S \rightarrow [0,1]$ tal que $f(S) \approx C^*$, onde S representa o vetor de *features* extraídas dos mapas de Stokes $\{S_0, S_1, S_2, S_3\}$ capturados pela câmera polarimétrica.

O estimador clássico de Stokes é definido diretamente pela Eq. (5) de [2]:

$$C_Stokes = \sqrt{(1 - (P_1^2 + P_2^2 + P_3^2) / P_0^2)}$$

Hipótese principal: *Um modelo PIML treinado com um conjunto de features físicas derivadas dos parâmetros de Stokes, cuja função de perda inclui uma penalidade de invariância, alcançará erro quadrático médio (RMSE) significativamente menor do que o estimador de Stokes puro em cenários com imperfeições de canal combinadas (turbulência + ruído + absorção parcial), mantendo viés residual inferior a 0,05 unidades de concorrência para $C^* \geq 0{,}50$.*

5. REVISÃO DA LITERATURA

Peters et al. [2] demonstraram pela primeira vez a invariância da concorrência em um enlace FSO real de 270 m. Nape et al. [3] haviam previsto teoricamente essa propriedade usando uma analogia quântica. Cox et al. [4] revisaram o impacto da turbulência em modos estruturados escalares e vetoriais, concluindo que a polarização como grau de liberdade oferece vantagens práticas apenas quando a não-separabilidade é corretamente monitorada. Zhu et al. [5] demonstraram comunicação de alta dimensão com feixes vetoriais resilientes à turbulência, corroborando a motivação prática.

No domínio de PIML para óptica, Rivenson et al. [6] aplicaram redes neurais profundas à recuperação de campo óptico a partir de imagens de intensidade, mostrando que redes treinadas com restrições físicas generalizam melhor para cenários de ruído não vistos durante o treino. Para estimação de parâmetros de Stokes, Durán et al. [7] usaram redes convolucionais para reduzir o número de medições polarimétrica necessárias, com resultados superiores ao método de mínimos quadrados clássico em cenários de baixa

SNR. Esses resultados motivam a aplicação de PIML especificamente para a estimação de concorrência.

6. METODOLOGIA

A metodologia será estruturada em quatro etapas:

Etapa 1 — Simulação do canal realista

Feixes vetoriais Laguerre-Gaussianos (p=0, $\ell=\pm1$) serão gerados computacionalmente e propagados por um canal FSO de 270 m modelado com telas de fase Kolmogorov (espectro de von Kármán). O modelo de imperfeições incluirá: (a) ruído shot e de leitura da câmera (SNR $\in$ [10, 30] dB); (b) erro de apontamento gaussiano ($\sigma_\theta \in$ [0, 1] mrad); (c) absorção parcial diferencial por aerossóis ($\alpha \in$ [0, 15%]); (d) crosstalk do PBS ($\varepsilon \in$ [0, 5%]).

Etapa 2 — Engenharia de features

Serão extraídas 17 features físicas dos mapas de Stokes recebidos: parâmetros de Stokes integrados normalizados (s_1 , s_2 , s_3), grau de polarização (DOP), variâncias espaciais de S_0 –S_3 , entropia de Shannon do perfil de intensidade, contraste do anel LG, correlação cruzada H-V, razão de potência H/V, coerência cruzada e o estimador de Stokes direto (como feature baseline).

Etapa 3 — Treinamento e avaliação dos modelos

Quatro modelos serão comparados: (i) Stokes clássico (baseline); (ii) Gradient Boosting (GBM); (iii) Rede neural com backpropagação manual incorporando penalidade física $|C_pred - C_Stokes|^2$ ponderada por λ (PINN); (iv) Stacked Ensemble com meta-aprendiz Ridge. O conjunto de dados incluirá 800 amostras de treino e 300 de teste, distribuídas uniformemente sobre $C^* \in \{0{,}05; 0{,}10; \ldots; 1{,}00\}$ e $r_0 \in \{0{,}006; 0{,}010; 0{,}018; 0{,}030; 0{,}060\}$ m. As métricas de avaliação serão RMSE, MAE e viés sistemático por faixa de C*.

Etapa 4 — Rastreamento temporal com Filtro de Kalman

Para simular o cenário experimental de Peters et al. — 120 minutos de monitoramento durante o pôr do sol com turbulência variável —, as predições do melhor modelo serão pós-processadas com um Filtro de Kalman escalar. O ganho de estabilidade temporal (redução de variância σ^2) será reportado como métrica adicional.

REFERÊNCIAS

[1] A. Forbes, M. de Oliveira, M. R. Dennis, "Structured light," Nature Photonics, vol. 15, pp. 253-262, 2021.

[2] C. Peters, M. Cox, A. Drozdov, A. Forbes, "The invariance and distortion of vectorial light across a real-world free space link," Appl. Phys. Lett., vol. 123, p. 021103, 2023.

[3] I. Nape et al., "Revealing the invariance of vectorial structured light in complex media," Nature Photonics, vol. 16, pp. 538-546, 2022.

[4] M. A. Cox et al., "Structured light in turbulence," IEEE J. Sel. Top. Quantum Electron., vol. 27, p. 7500521, 2021.

[5] Z. Zhu et al., "Compensation-free high-dimensional free-space optical communication using turbulence-resilient vector beams," Nature Commun., vol. 12, p. 1666, 2021.

[6] Y. Rivenson et al., "Phase recovery and holographic image reconstruction using deep learning in neural networks," Light: Sci. Appl., vol. 7, p. 17141, 2018.

[7] V. Duran et al., "Snapshot Stokes imaging with a single-shot polarimeter using convolutional neural networks," Optics Express, vol. 29, pp. 15340-15355, 2021.