


TP558 - Tópicos avançados em Machine Learning: *MobileNets*



Abertura

- apresenta uma arquitetura de redes neurais convolucionais desenvolvida especificamente para aplicações de visão computacional em dispositivos móveis e sistemas embarcados
- propõe uma estratégia para reduzir número de parâmetros, operações computacionais, memória e latência, mantendo uma precisão competitiva.
- trabalho aponta uma contradição importante na evolução das CNNs

Arquiteturas profundas apresentavam ganhos significativos de precisão, mas esses ganhos normalmente vinham acompanhados:

- maior número de parâmetros;
- maior quantidade de operações;
- maior consumo de memória;
- maior latência;
- maior necessidade de processamento


Isso representa um problema quando a rede precisa executar diretamente em dispositivos com recursos limitados

- smartphones;
- sistemas embarcados;
- robôs;
- veículos autônomos;
- sistemas de realidade aumentada.

Não basta construir uma rede pequena em termos de armazenamento: é necessário também considerar **velocidade e custo computacional**.

■ Parâmetros (M) ■ Mult-Adds (M)

Modelo



Modelos como VGG16 possuem 138 milhões de parâmetros e 15,3 bilhões de Mult-Adds (medida de processamento computacional) — completamente inviáveis para dispositivos móveis.

Introdução do artigo

- proposta dos autores é, portanto, construir uma arquitetura que permita escolher explicitamente o compromisso entre:

precisão × tamanho × quantidade de computação × latência

- principal contribuição do artigo é a arquitetura denominada MobileNet
- ideia fundamental consiste em substituir as convoluções convencionais por depthwise separable convolutions — convoluções separáveis em profundidade

Conceito

Operação convencional de convolução é dividida em duas etapas:

1. Depthwise convolution
2. Pointwise convolution 1×1 .

Essa é ideia por traz do artigo, onde a fatoração reduz drasticamente o custo computacional da CNN

Fundamentação teórica

Uma camada convolucional padrão recebe um mapa de características de entrada F com dimensões $D_F \times D_F \times M$ e produz um mapa de saída G com dimensões $D_F \times D_F \times N$.

onde:

- D_F é a largura e altura espacial do mapa de características.
- M é o número de canais de entrada (profundidade de entrada).
- N é o número de canais de saída (profundidade de saída).
- D_K é a dimensão espacial do kernel

$$G_{k,l,n} = \sum_{i,j,m} K_{i,j,m,n} \cdot F_{k+i-1,l+j-1,m}$$

(1)

$$D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F$$

(2)

Fundamentação teórica

Convoluções Separáveis em Profundidade para quebrar a interação direta entre o tamanho do kernel e o número de canais de saída, os autores dividem o processo em duas partes matemáticas:

Convolução Depthwise (Filtragem): Aplica um único filtro espacial para cada canal de entrada de forma independente.


$$\hat{\mathbf{G}}_{k,l,m} = \sum_{i,j} \hat{\mathbf{K}}_{i,j,m} \cdot \mathbf{F}_{k+i-1,l+j-1,m}$$

(3)

$$D_K \cdot D_K \cdot M \cdot D_F \cdot D_F$$

(4)

Convolução Pointwise: Combinação de Canais



Mecanismo

- Aplica um único filtro por canal de entrada — não combina canais entre si
- Kernel de tamanho $D_K \times D_K \times M$ (um filtro por canal)

Limitação e Complemento

- A camada depthwise apenas filtra — não gera novas representações entre canais
- Necessita obrigatoriamente da etapa pointwise subsequente

Fundamentação teórica

Convolução Pointwise (Combinação): Como a etapa anterior não combina os canais para gerar novas representações, utiliza-se uma convolução simples de 1x1 para criar uma combinação linear das saídas da camada depthwise.

$$M \cdot N \cdot D_F \cdot D_F$$

(5)


Função custo Pointwise

$$D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F$$

(6)

Função custo total


Convolução Pointwise: Combinação de Canais



Mecanismo da Camada 1×1

- Convolução 1×1 que combina linearmente as saídas da camada depthwise
- Gera N novos mapas de características a partir dos M canais filtrados
- Implementável diretamente via GEMM (General Matrix Multiply) — sem necessidade de im2col

Convolução Padrão vs Depthwise Convolution



Fator de Redução Matemática


Ao expressar a convolução como um processo de duas etapas, a matemática demonstra uma redução direta na computação, calculada pela razão entre os custos

$$\frac{D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F}{D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F} = \frac{1}{N} + \frac{1}{D_K^2}$$

(7)

Como o MobileNet utiliza kernels de dimensão 3x3 ($D_K=3$), a redução matemática chega a ser 8 a 9 vezes menor em comparação com a convolução padrão, custando apenas uma pequena fração da precisão

Comparação Visual: Camada Padrão vs. Separável



Camada Padrão

Conv 3×3 → BatchNorm → ReLU

Uma única operação acoplada que realiza filtragem e combinação de canais simultaneamente.

Camada Separável em Profundidade

Depthwise 3×3 → BN → ReLU → Pointwise 1×1 → BN → ReLU

Ambas as sub-camadas aplicam **BatchNorm e ReLU** após cada convolução. A separação em duas etapas permite otimização independente de filtragem e combinação, sem perda de capacidade representacional significativa.

Estrutura Completa da Rede MobileNet

Arquitetura Camada a Camada

- **28 camadas** no total (depthwise e pointwise contadas separadamente)
- Primeira camada: **convolução completa 3×3** com stride 2 (entrada $224\times 224\times 3$)
- Bloco principal: pares depthwise + pointwise com canais crescendo de 32 $\rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512 \rightarrow 1024$
- Downsampling via **strided convolutions** (não pooling) nas camadas depthwise
- Final: Average Pooling $7\times 7 \rightarrow$ Fully Connected $1024\times 1000 \rightarrow$ Softmax

📌 **95%** do tempo de computação é gasto em convoluções 1×1 — altamente otimizáveis via GEMM.

Distribuição de Recursos por Tipo de Camada

Tipo de Camada	Mult-Adds (%)	Parâmetros (%)
Conv 1×1	94.86%	74.59%
Conv DW 3×3	3.06%	1.06%
Conv 3×3	1.19%	0.02%
Fully Connected	0.18%	24.33%

Hiperparâmetros

Introduziram dois parâmetros que permitem controlar o tamanho da rede

α

Nomeado como width multiplier, ele controla a quantidade de canais da rede.

Quanto menor α , menor o número de parâmetros, quantidade de operações, tamanho do modelo, latência. Mas também também existe redução da precisão.

O artigo observa que a redução de custo e parâmetros é aproximadamente quadrática com α .


Width Multiplier (α): Modelos Mais Finos

Como Funciona

Parâmetro $\alpha \in (0, 1]$ que reduz uniformemente o número de canais em cada camada. Para uma dada camada, o número de canais de entrada M torna-se αM e os canais de saída N tornam-se αN .

Reduz custo computacional e parâmetros **quadraticamente** (α^2). Pode ser aplicado a qualquer arquitetura, mas requer treinamento do zero.

Valores típicos: $\alpha = 1, 0.75, 0.5, 0.25$



Reduzir o width multiplier diminui drasticamente os Multi-Adds com queda moderada de acurácia até $\alpha=0.5$ — abaixo disso, a queda se torna mais abrupta, sugerindo um limite prático de compressão.

Hiperparâmetros

Outro parâmetro que permite controlar o tamanho da rede

ρ

Nomeado como resolution multiplier, controla a resolução espacial da entrada e, consequentemente, das representações internas, assim a ideia é reduzir a resolução da imagem

A grande vantagem da proposta é que os dois parâmetros podem ser combinados: α controla a largura da rede, ρ controla a resolução espacial

$$D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F$$

(6)

Função custo total


Resolution Multiplier (ρ): Representação Reduzida

Como Funciona

Parâmetro $\rho \in (0, 1]$ aplicado à **imagem de entrada** — reduz todas as representações internas proporcionalmente. Na prática, ρ é definido implicitamente pela resolução de entrada escolhida.

Reduz custo computacional por ρ^2 — **sem alterar o número de parâmetros**. A acurácia cai suavemente com a resolução.

Resoluções típicas: **224, 192, 160, 128 pixels**



A acurácia cai de forma suave e previsível com a redução da resolução — de **70.6% em 224px para 64.4% em 128px** — enquanto os Multi-Adds caem em mais de **3×**, com número de parâmetros constante em 4.2M.

Hiperparâmetros

Aplicando esses multiplicadores, a equação final que define o custo computacional das camadas centrais do MobileNet:

$$D_K \cdot D_K \cdot \alpha M \cdot \rho D_F \cdot \rho D_F + \alpha M \cdot \alpha N \cdot \rho D_F \cdot \rho D_F$$

(8)

EXPERIMENTOS

- MobileNet vs. convolução completa: usar convoluções separáveis reduz a acurácia em apenas ~1% (71,7% → 70,6% no ImageNet), mas corta Mult-Adds de 4866M para 569M e parâmetros de 29,3M para 4,2M.
- Redes finas vs. rasas: tornar a rede mais "fina" (width multiplier) é 3% melhor em acurácia do que torná-la mais "rasa" (menos camadas), com custo computacional equivalente.

Comparação com modelos populares:

- Contra VGG16: acurácia quase equivalente (70,6% vs. 71,5%), mas 32× menor e 27× menos computação.
- Contra GoogleNet: mais precisa (70,6% vs. 69,8%) e mais eficiente.
- Versão reduzida (0.5 MobileNet-160) supera AlexNet em 4% de acurácia sendo 45× menor e 9,4× menos custosa; também supera SqueezeNet em acurácia com 22× menos computação.

Aplicações Demonstradas

O artigo valida o MobileNet como extrator de features em diversas tarefas:


- Classificação fine-grained (Stanford Dogs): resultados próximos ao estado da arte (Inception V3) com muito menos recursos.
- Geolocalização em larga escala (PlaNet): versão MobileNet do PlaNet usa apenas 13M parâmetros (vs. 52M do original) com desempenho ligeiramente inferior, mas ainda superando o Im2GPS.
- Atributos faciais: combinado com destilação de conhecimento (distillation), o MobileNet reproduz o desempenho de um classificador maior usando apenas 1% dos Mult-Adds.
- Detecção de objetos (COCO, com frameworks SSD e Faster-RCNN): desempenho comparável a VGG e Inception V2 com fração do custo computacional.
- Embeddings faciais (destilado do FaceNet): reduz drasticamente o tamanho mantendo boa acurácia.

Reconhecimento Fino: Stanford Dogs Dataset

Desafio e Estratégia

Tarefa: classificação de **120 raças de cães** — exige discriminação de características extremamente sutis entre classes visualmente similares.

Estratégia: pré-treino com **dados ruidosos da web** + fine-tuning no Stanford Dogs. Os dados web introduzem variabilidade que melhora generalização mesmo contendo ruído.




✓ 1.0 MobileNet-224 atinge **83.3% Top-1** — quase estado da arte — com **8.8× menos computação** que o Inception V3 (569M vs. 5000M Mult-Adds).

Geolocalização em Larga Escala: PlaNet com MobileNet

O Problema PlaNet

PlaNet determina a **localização geográfica de fotos** como problema de classificação — divide o globo em células geográficas e prevê em qual célula a foto foi tirada. Um dos problemas de classificação mais desafiadores em visão computacional.

Modelo	Params	Mult-Adds
PlaNet (Inception V3)	52M	5.74B
PlaNet MobileNet	13M	0.58B



MobileNet é **~10× mais compacto** que o PlaNet original e ainda **supera o modelo base em nível continental** (79.3% vs. 77.6%). Ambos superam Im2GPS por larga margem em todas as escalas geográficas.


Atributos Faciais: MobileNet + Destilação

Configuração do Experimento

Objetivo: comprimir classificador de atributos faciais com **75M parâmetros** e **1600M Mult-Adds**.

A destilação permite treinar o MobileNet para imitar as **saídas do modelo grande** em vez dos ground-truth labels — viabilizando uso de datasets não rotulados em escala.

Sem necessidade de weight decay ou early stopping — o modelo é resiliente à compressão agressiva.



✓ **0.25 MobileNet-128** mantém 86.4% Mean AP com apenas **15M Mult-Adds** — menos de 1% do custo computacional do baseline original.

Detecção de Objetos: MobileNet SSD e Faster-RCNN



Avaliação no COCO Dataset

Modelo	mAP	Mult-Adds
MobileNet SSD 300	19.3%	1.2B
VGG SSD 300	23.2%	34.9B
MobileNet Faster-RCNN 600	19.8%	30.5B
VGG Faster-RCNN 600	22.9%	149.6B

Análise de Eficiência

MobileNet SSD 300 atinge resultados comparáveis com **29× menos computação** que o VGG-SSD (1.2B vs. 34.9B Mult-Adds).


O framework SSD revela-se particularmente adequado para o MobileNet — a arquitetura leve combina bem com a estratégia de detecção em múltiplas escalas do SSD.

Reconhecimento Facial: FaceNet Destilado

FaceNet e Destilação

FaceNet: modelo estado da arte baseado em **triplet loss** — 1600M Mult-Adds, 7.5M parâmetros. MobileNet treinado por destilação minimizando a **diferença quadrática** das saídas do FaceNet nos dados de treino.

Objetivo: viabilizar reconhecimento facial de alta qualidade **diretamente no dispositivo móvel**, sem necessidade de chamada a servidor.



0.75 MobileNet-128 atinge 72.5% de acurácia com apenas **108M Mult-Adds** — **14.8× menos computação** que o FaceNet original, mantendo desempenho útil para aplicações on-device.

Insights

GEMM sem im2col

Convoluções 1×1 não precisam de reordenamento de memória — implementação direta com GEMM, um dos algoritmos de álgebra linear numérica mais otimizados disponíveis em hardware moderno.

Concentração de Computação

95% do tempo em convoluções 1×1 — cria um único ponto de otimização. Ao contrário de arquiteturas heterogêneas, o esforço de otimização de hardware é altamente focado.

Profundidade Preservada

Manter profundidade (vs. reduzir largura) é **3% melhor** — hierarquia de features é essencial. Representações de alto nível requerem múltiplos estágios de abstração.

Regularização Mínima

Modelos pequenos **não sofrem de overfitting** — menos data augmentation necessário. Isso simplifica o pipeline de treinamento e torna reprodução mais acessível.

Destilação Sinérgica

Combinar MobileNet com knowledge distillation amplifica eficiência sem perda significativa. Atributos faciais: 0.25
MobileNet-128 supera baseline com 1% do custo computacional.

Limitações e Considerações


Limitações Técnicas

- **Queda abrupta em $\alpha=0.25$:** modelos muito pequenos sofrem colapso de acurácia — limite prático de compressão irreversível pela simples redução de largura
- **Operações esparsas:** matrizes esparsas não são mais rápidas que densas até altíssima esparsidade — limita abordagens de pruning como complemento ao MobileNet
- **Treinamento do zero:** width multiplier requer retreinamento completo — não é um ajuste pós-treinamento aplicável a modelos já treinados

Gaps de Desempenho por Aplicação

- **Deteção de objetos:** gap de mAP em relação ao VGG/Inception em frameworks Faster-RCNN (19.8% vs. 22.9% de mAP) — custo de eficiência real
- **Geolocalização regional:** PlaNet MobileNet perde para o original em escalas menores — cidade (31.7% = empate) e região (45.2% vs. 51.1%)
- **FaceNet destilado:** gap de 3.6 pontos percentuais vs. FaceNet original mesmo no melhor modelo MobileNet

Impacto e Legado do MobileNet



Democratização da Visão Computacional

MobileNets democratizaram visão computacional em dispositivos de borda: **smartphones, câmeras IoT, drones** — tornando inteligência artificial acessível sem dependência de infraestrutura de nuvem. Modelos publicados no TensorFlow impulsionaram adoção massiva na comunidade.

Framework Duradouro

O framework de dois hiperparâmetros (α , p) tornou-se **referência padrão** para design de redes eficientes. A intuição de separar filtragem e combinação de canais permanece central em arquiteturas modernas de visão computacional eficiente.

Reprodução do experimento

UTILIZANDO O CIFAR-10				
ALPHA	MAC	PARAMETROS	ACURÁCIA CIFAR-10	ACURÁCIA IMAGENET (PAPER)
1.00	104.3	3.22	77,2%	70,6%
0.50	27.4	0.82	72,3%	63,7%
0.25	7.5	0.22	63,6%	50,6%

Conclusão: Inteligência Eficiente no Dispositivo

MobileNets provam que é possível obter **alta acurácia com baixíssimo custo computacional** via convoluções separáveis em profundidade — redefinindo o que é possível em hardware limitado.

Resultado Central

8–9× menos computação com apenas **1% de perda de acurácia** vs. convoluções padrão — a troca mais impactante documentada no paper.

Dois Hiperparâmetros

α e ρ permitem ajuste preciso do trade-off **latência** × **acurácia** × **tamanho** em qualquer ponto do espectro de hardware.

5 Domínios Validados

Classificação ImageNet, reconhecimento fino, geolocalização, atributos faciais e detecção de objetos — eficácia comprovada amplamente.

Visão Realizada

Inteligência de visão computacional acessível em **qualquer dispositivo**, sem dependência de nuvem — viabilizando aplicações antes impossíveis.

Perguntas?


Referências

[1] Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., ... & Adam, H. (2017). MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. [arXiv preprint arXiv:1704.04861](https://arxiv.org/abs/1704.04861). Google Inc

[2] Z. Li, F. Liu, W. Yang, S. Peng and J. Zhou, "A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects," in *IEEE Transactions on Neural Networks and Learning Systems*, vol. 33, no. 12, pp. 6999-7019, Dec. 2022, [doi: 10.1109/TNNLS.2021.3084827](https://doi.org/10.1109/TNNLS.2021.3084827). keywords: {Convolutional neural networks;Feature extraction;Neurons;Deep learning;Computer vision;Computer vision;convolutional neural networks (CNNs);deep learning;deep neural networks}

Obrigado!

QUESTIONÁRIO



https://docs.google.com/forms/d/e/1FAIpQLScoUFAq9P2XRNeDUS47GWcy19Mtv8dtMc98BkeVA_h-oIVwgg/viewform?usp=header