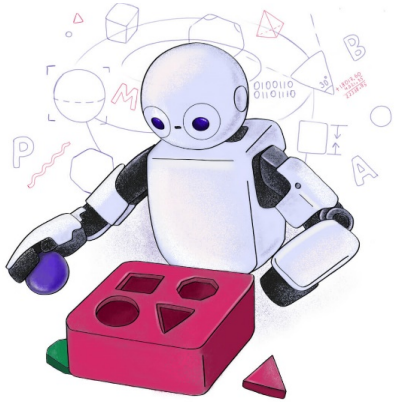
TP558 - Tópicos avançados em Machine Learning:

SVM



Inatel

Fábio Augusto Pereira
fabio.pereira@mtel.inatel.br

PROPOSTA

Proposta de uma abordagem que procura controlar sobreajuste por meio da geometria da fronteira de decisão e da otimização matemática.

- Construir classificadores com capacidade de separar duas classes de padrões.
- Maximizar a margem entre a fronteira de decisão e os exemplos das classes.
- Estender o método para conjuntos de dados que não são perfeitamente separáveis.
- Utilizar transformações não lineares para construir fronteiras de decisão complexas.
- Avaliar experimentalmente o método em problemas artificiais e no reconhecimento de dígitos manuscritos.
- Comparar os resultados com classificadores lineares, árvores de decisão, vizinhos mais próximos e redes neurais.

Demonstrar que um classificador pode operar em espaços de características de dimensão extremamente elevada sem precisar construir explicitamente todas essas características.

A IDEIA CENTRAL: SEPARAR MELHOR PARA GENERALIZAR MELHOR

1 **Mapeamento não linear**

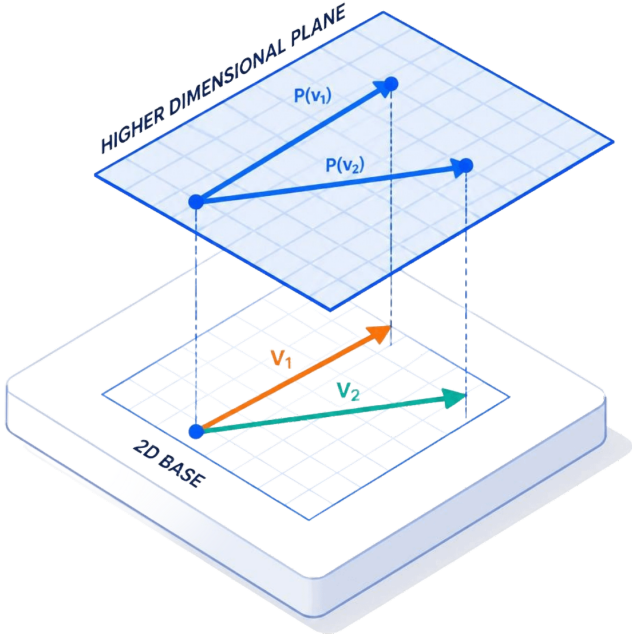
Mapear os vetores de entrada $\mathbf{x} \in R^n$ para um espaço de características de alta dimensão H.

2 **Hiperplano ótimo de separação**

Construir em H uma superfície linear de decisão com propriedades especiais de generalização teórica.

3 **Robustez estrutural**

Controlar a capacidade do classificador geometricamente, desacoplando o erro de teste da dimensionalidade do espaço.



Inatel

POR QUE CLASSIFICADORES LINEARES IMPORTAM?

Da regra de Fisher

Fisher provou que, sob distribuições gaussianas com matrizes de covariância distintas, a fronteira bayesiana ótima é quadrática. Quando as matrizes de covariância coincidem, a regra ótima reduz-se exatamente a uma função linear.

Função Quadrática

$$\frac{n(n+3)}{2}$$

Parâmetros livres exigidos; cresce com o quadrado da dimensão.

Função Linear

$$n + 1$$

Parâmetros livres; estimativa muito mais confiável com dados finitos.

Princípio prático: com amostras limitadas, restringir a classe de funções é indispensável para evitar variância excessiva.



Inatel

DO PERCEPTRON À SUPERFÍCIE EM ESPAÇO DE CARACTERÍSTICAS

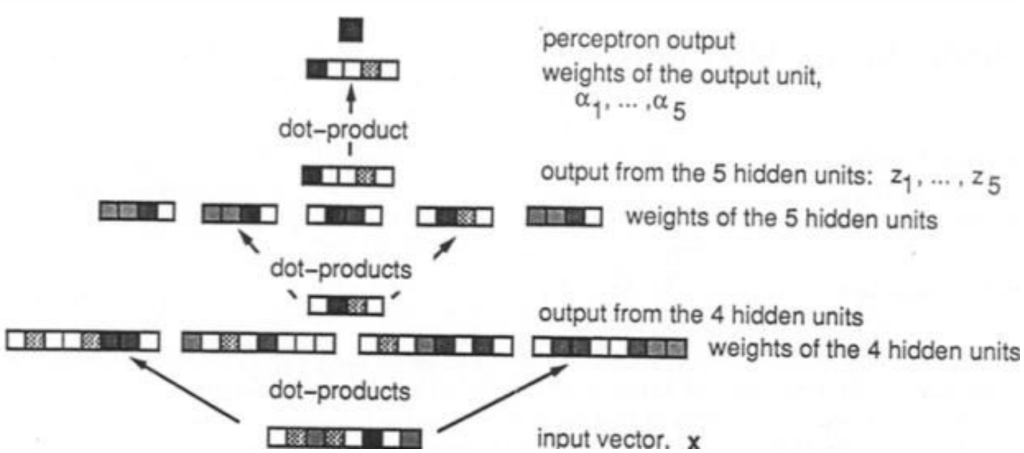


Figura 1 do artigo original: mapeamento não linear $\mathbf{z} = \phi(\mathbf{x})$ seguido de separador linear.

Estrutura de representação

O perceptron transforma o vetor de entrada **x** por meio de funções nas camadas ocultas e projeta os dados em um novo espaço de representação z .

O dilema clássico

Enquanto redes neurais ajustam heurística e iterativamente os pesos de todas as camadas, as SVNs fixam o mapeamento e resolvem a última camada por otimização convexa global com controle estrito de margem.

Inatel

A VIRADA: MARGEM MÁXIMA

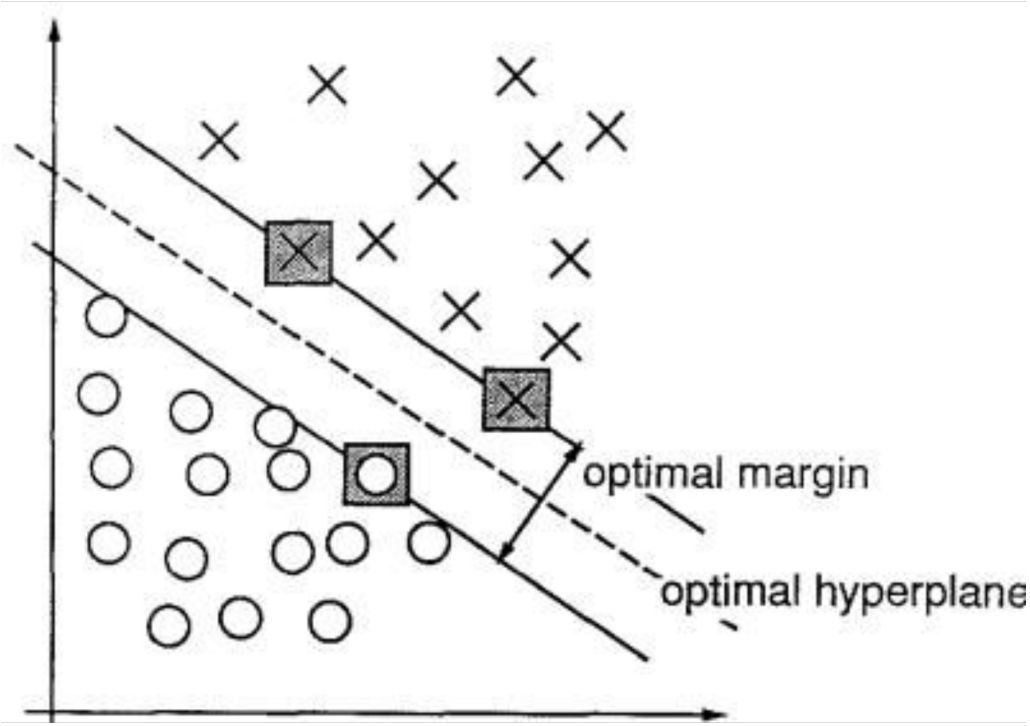


Figura 2 do artigo original: hiperplano central e planos canônicos de suporte delimitando a margem.

CONTROLE GEOMÉTRICO

Critério do hiperplano ótimo

Entre as infinitas superfícies que separam perfeitamente duas classes separáveis, escolhe-se a que maximiza a distância mínima aos pontos mais próximos de ambas.

$$\rho = \frac{2}{\| \mathbf{w} \|}$$

A margem geométrica ρ formaliza a regularização: margem maior implica menor capacidade (dimensão VC) e classificação mais estável.

VETORES DE SUPORTE: OS PONTOS QUE DEFINEM A MARGEM

1

Localização crítica

Somente os exemplos situados exatamente sobre as fronteiras da margem possuem multiplicadores $\alpha_i > 0$.

2

Indiferença aos pontos internos

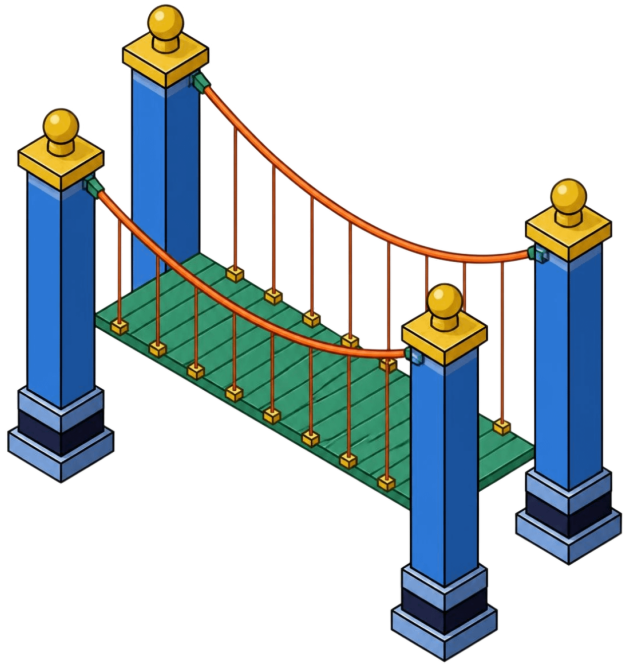
Afastar ou remover qualquer ponto com $\alpha_i = 0$ deixa o hiperplano ótimo rigorosamente idêntico.

3

Representação condensada

O vetor normal do hiperplano é uma combinação linear direta apenas desse subconjunto crítico de treino:

$$\mathbf{w}_0 = \sum_{i \in SV} \alpha_i y_i \mathbf{x}_i$$



Inatel

O LIMITE DE GENERALIZAÇÃO BASEADO EM VETORES DE SUPORTE

TEOREMA DE VAPNIK

$$E[\text{erro}] \leq \frac{E[N_{SV}]}{l}$$

Métrica	Valor conceitual
Vetores de suporte / treino	quanto menor, melhor
Erro esperado	limitado pela razão

Para dados separáveis, o erro esperado é limitado pela razão entre o número esperado de vetores de suporte e o número de exemplos de treino.

FORMULAÇÃO PRIMAL: DA GEOMETRIA À PROGRAMAÇÃO QUADRÁTICA

1. DADOS E RÓTULOS

Amostras canônicas

Conjunto de treino com rótulos bipolares:

$$(\mathbf{x}_i, y_i), \quad y_i \in \{-1, +1\}$$

$i = 1, \ldots, l$

2. RESTRIÇÕES DE SEPARAÇÃO

Faixa da margem

Nenhum exemplo penetra o canal da margem:

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1$$

Garante separação estrita e correta.

3. PROBLEMA PRIMAL

Minimizar $||\mathbf{w}||^2$

Maximizar $\rho = \frac{2}{\|\mathbf{w}\|}$ equivale a resolver:

$$\min_{\mathbf{w},b} \frac{1}{2} \|\mathbf{w}\|^2$$

Programação quadrática estritamente convexa.

Propriedade fundamental: como a função custo é puramente quadrática e as restrições são lineares, não existem mínimos locais; a solução ótima é única e global.

Inatel

MULTIPLICADORES DE LAGRANGE E A FORMA DUAL

LAGRANGIANO PRIMAL

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \tfrac{1}{2}\|\mathbf{w}\|^2 - \sum_{i=1}^{l} \alpha_i \left[y_i(\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \right]$$

Gradientes primais nulos:

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \implies \mathbf{w} = \sum_{i=1}^{l} \alpha_i y_i \mathbf{x}_i,$$

$$\frac{\partial L}{\partial b} = 0 \implies \sum_{i=1}^{l} \alpha_i y_i = 0$$

PROBLEMA DUAL DE WOLFE

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{l} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{l} \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j)$$

Sujeito a: $\alpha_i \geq 0$ e $\sum_{i=1}^{l} \alpha_i y_i = 0$.

Conclusão: os dados aparecem exclusivamente através de produtos internos $(\mathbf{x}_i \cdot \mathbf{x}_j)$, jamais de forma isolada.

CONDIÇÃO DE KARUSH–KUHN–TUCKER

KKT 1 **Viabilidade Primal:** $y_i(\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0, \quad \forall i$

KKT 2 **Viabilidade Dual:** $\alpha_i \geq 0, \quad \forall i$

KKT 3 **Folga Complementar:** $\alpha_i [y_i(\mathbf{w} \cdot \mathbf{x}_i + b) - 1] = 0, \quad \forall i$

Origem da esparsidade na solução

Se o exemplo está estritamente fora da margem ($y_i(\mathbf{w} \cdot \mathbf{x}_i + b) > 1$), a folga complementar força rigorosamente $\alpha_i = 0$
Se $\alpha_i > 0$, o ponto está obrigatoriamente na margem canônica ($y_i(\mathbf{w} \cdot \mathbf{x}_i + b) = 1$).

O CLASSIFICADOR VISTO COMO UMA REDE DE DUAS CAMADAS

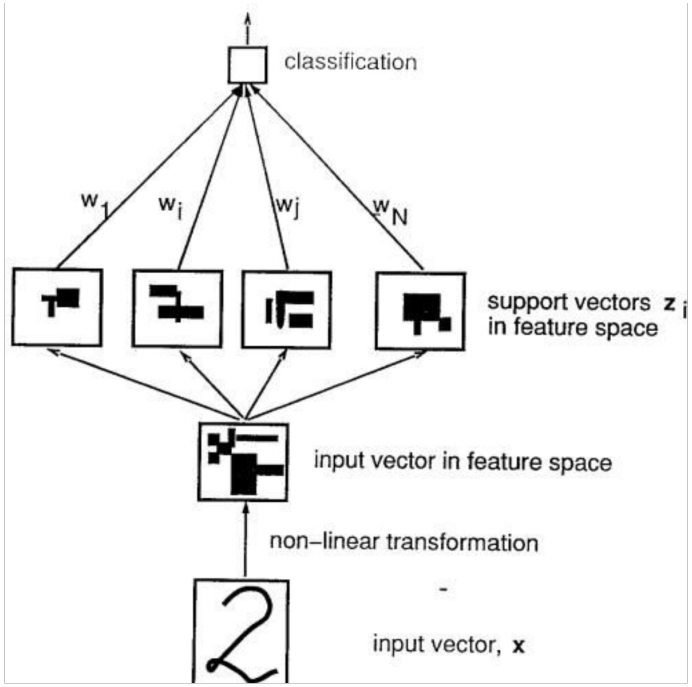


Figura 3 do artigo original: rede de convolução de produto interno e combinação linear dos pesos.

ARQUITETURA FEEDFORWARD

Regra de decisão da SVN

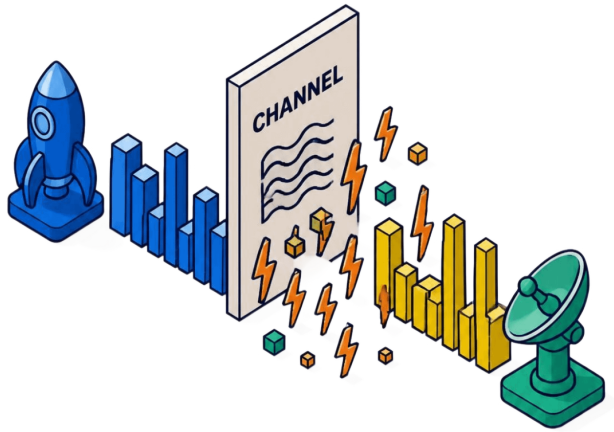
$$f(\mathbf{x}) = \operatorname{sgn}\left(\sum_{i=1}^{N_{sv}} \alpha_i y_i (\mathbf{x} \cdot \mathbf{s}_i) + b\right)$$

1ª Camada: computa os produtos internos entre a entrada $\mathbf{x}$ e cada vetor de suporte fixado $\mathbf{s}_i$.

2ª Camada: combina os produtos ponderados por $w_i = \alpha_i y_i$, adiciona o limiar b e aplica a função degrau $\operatorname{sgn}(\cdot)$.

QUANDO A SEPARAÇÃO PERFEITA FALHA

- Dados reais podem se sobrepor, conter ruído ou possuir rótulos incompatíveis.
- Forçar margem rígida pode produzir um classificador frágil ou inviável.



MARGEM SUAVE: PERMITIR VIOLAÇÕES CONTROLADAS

VARIÁVEIS DE FOLGA

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

As variáveis ξ_i quantificam desvios individuais:

$\xi_i = 0$: ponto perfeitamente classificado fora ou na margem.

$0 < \xi_i \leq 1$: ponto no lado correto, mas dentro da margem.

$\xi_i > 1$: erro de classificação no conjunto de treino.

OBJETIVO COM REGULARIZAÇÃO

$$\min_{\mathbf{w},b,\boldsymbol{\xi}} \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{l} \xi_i$$

O objetivo concilia duas forças concorrentes:

$\frac{1}{2}\|\mathbf{w}\|^2$: maximiza a largura da margem (simplicidade do modelo).

$C\sum\xi_i$: penaliza o montante acumulado de violações de margem.

Inatel

O PAPEL DE C NA PRÁTICA

CONFIGURAÇÃO DE HIPERPARÂMETRO

O compromisso fundamental

O parâmetro *C* age como uma constante de regularização inversa: dita o peso atribuído aos erros de treinamento em relação à largura geométrica da margem.

IMPACTO NO PROJETO

Em canais muito ruidosos com baixa relação sinal-ruído (SNR), um *C* moderado ou baixo é mandatório para impedir que ruído térmico aleatório deforme a superfície de decisão.

Configuração	Margem	Penalidade	Risco
C baixo	Mais ampla	Menor	Subajuste
C alto	Mais estreita	Maior	Sobreajuste

BOX

A restrição de caixa (box constraint) é a única alteração funcional no problema dual ao passar da margem rígida para a suave.

$0 \le \alpha_i \le C$

O DUAL DA MARGEM SUAVE

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{l} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{l} \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j)$$

✓ *Caixa Superior:* $0 \le \alpha_i \le C$ limita o impacto máximo de qualquer amostra anômala individual.

✓ Equilíbrio de Classe: A restrição de igualdade linear $\sum_{i=1}^{l} \alpha_i y_i = 0$ permanece inalterada.

✓ Tipos de Suporte:

Pontos na margem possuem $0 < \alpha_i < C$ ($\xi_i = 0$); pontos violadores ou com erro têm $\alpha_i = C$ ($\xi_i > 0$).

O PROBLEMA TÉCNICO: ESPAÇOS DE DIMENSÃO ENORME

GRAU 2 (256 PIXELS)

~33.000

dimensões no espaço expandido de características.

GRAU 4 (256 PIXELS)

~10^9

um bilhão de coordenadas para cada amostra.

GRAU 7 (256 PIXELS)

~10^{16}

dez quatrilhões de coordenadas; intratável na memória.

Construir e armazenar explicitamente o vetor $\phi(\mathbf{x})$ coordenada a coordenada é impossível em hardware computacional. A solução consiste em nunca calcular as coordenadas individuais, mas apenas seus produtos internos.

KERNEL TRICK: CALCULAR SIMILARIDADES SEM MAPEAR EXPLICITAMENTE

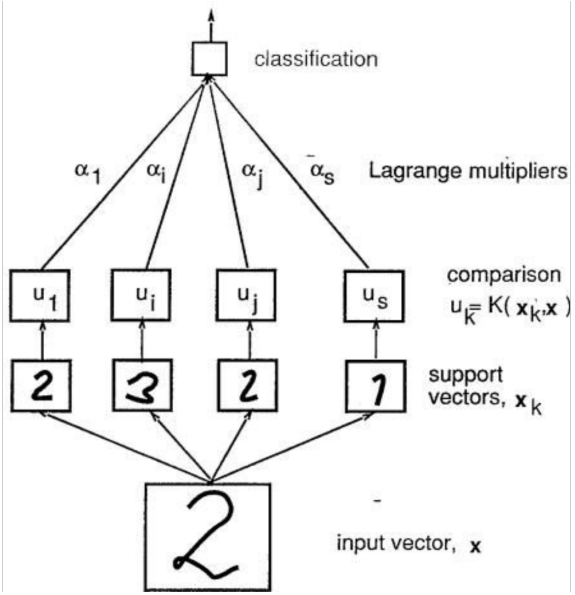


Figura 4 do artigo original: cálculo implícito do produto interno em alta dimensão via função núcleo.

PRODUTO INTERNO CONVOLUÍDO

$$K(\mathbf{u}, \mathbf{v}) = \phi(\mathbf{u}) \cdot \phi(\mathbf{v})$$

Substituindo $(\mathbf{x}_i \cdot \mathbf{x}_j)$ por $K(\mathbf{x}_i, \mathbf{x}_j)$, todo o treinamento dual e a função de decisão operam em H consumindo apenas o custo computacional do espaço original de entrada R^n.

$$f(\mathbf{x}) = \operatorname{sgn}\left(\sum_{i \in \mathrm{SV}} \alpha_i y_i K(\mathbf{x}, \mathbf{s}_i) + b\right)$$

Inatel

MERCER: QUANDO UMA FUNÇÃO PODE SER UM KERNEL

TEOREMA DE MERCER (1909)

Condição necessária e suficiente

Para que $K(\mathbf{u}, \mathbf{v})$ represente um produto interno em algum espaço de Hilbert H, a forma quadrática integral correspondente deve ser semidefinida positiva:

$$\iint K(\mathbf{u}, \mathbf{v}) g(\mathbf{u}) g(\mathbf{v})\, d\mathbf{u}\, d\mathbf{v} \geq 0$$

Para qualquer função $g \in L_2$ de quadrado integrável.

MATRIZ DE GRAM VISUAL

$$\mathbf{K} = \begin{bmatrix} K(\mathbf{x}_1, \mathbf{x}_1) & K(\mathbf{x}_1, \mathbf{x}_2) & \dots \\ K(\mathbf{x}_2, \mathbf{x}_1) & K(\mathbf{x}_2, \mathbf{x}_2) & \dots \\ \vdots & \vdots & \end{bmatrix}$$

1. Simetria: $K(\mathbf{x}_i, \mathbf{x}_j) = K(\mathbf{x}_j, \mathbf{x}_i)$

2. Positividade: $\mathbf{c}^T \mathbf{K} \mathbf{c} \geq 0, \ \forall \mathbf{c} = \mathbf{0}$

3. Similaridade: a diagonal mede auto-similaridade máxima.

KERNEL POLINOMIAL

D = 1

$K(\mathbf{u}, \mathbf{v}) = \mathbf{u} \cdot \mathbf{v} + 1$

Hiperplano linear com termo de bias integrado.

D = 2

$K(\mathbf{u}, \mathbf{v}) = (\mathbf{u} \cdot \mathbf{v} + 1)^2$

Fronteiras Cônicas: elipses, parábolas e hipérboles.

D = 4 \DOTS 7

$K(\mathbf{u}, \mathbf{v}) = (\mathbf{u} \cdot \mathbf{v} + 1)^d$

Interações de alta ordem sem custo combinatorial.

Cortes e Vapnik avaliaram graus de 1 a 7 no artigo original, comprovando viabilidade de execução idêntica em qualquer grau.

KERNEL RBF E CONHECIMENTO PRÉVIO

FUNÇÃO DE BASE RADIAL (GAUSSIANA)

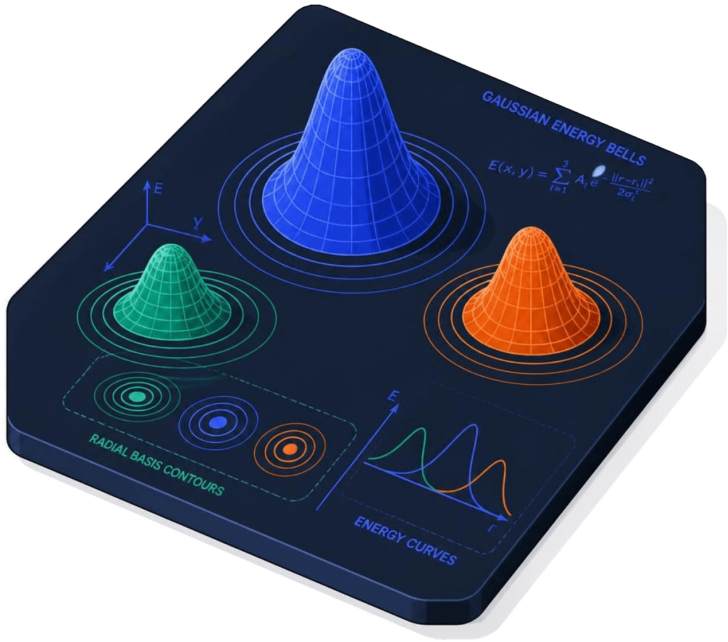
$$K(\mathbf{u}, \mathbf{v}) = \exp\left(-\frac{\|\mathbf{u} - \mathbf{v}\|^2}{\sigma^2}\right)$$

Espaço de Hilbert de dimensão infinita

A expansão de Taylor do exponencial revela que o kernel RBF projeta os dados em um espaço com infinitas dimensões. A métrica avalia similaridade puramente local baseada na distância euclidiana.

Injeção de conhecimento a priori

Kernels podem ser desenhados para embutir invariâncias físicas: rotação de fase, atraso de grupo em canais, correlação espectral e simetrias de modulação.



Inatel

CONTROLE DE CAPACIDADE E RISCO ESTRUTURAL

ERRO DE TESTE E CAPACIDADE

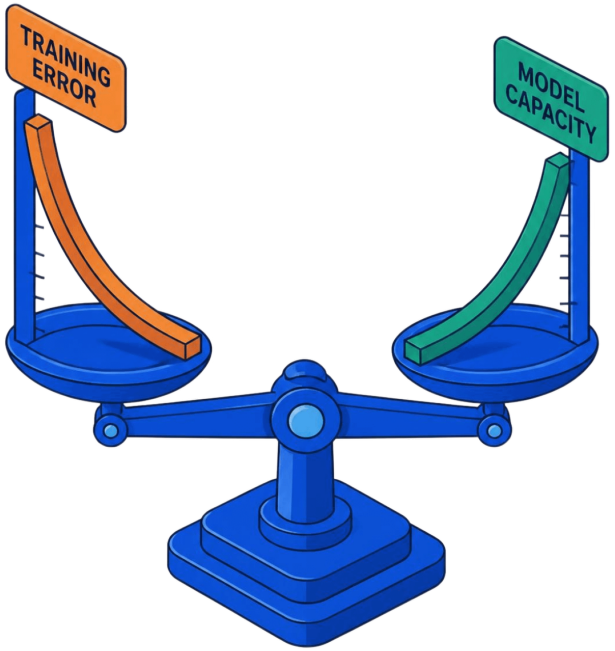
O erro de teste combina frequência de erro no treino e um intervalo de confiança.

Erro de teste

A dimensão VC mede a capacidade da classe de funções.

Princípio de Occam

Minimizar $\|\mathbf{w}\|^2$ reduz sobreajuste.



Inatel

EXPERIMENTO GEOMÉTRICO NO PLANO

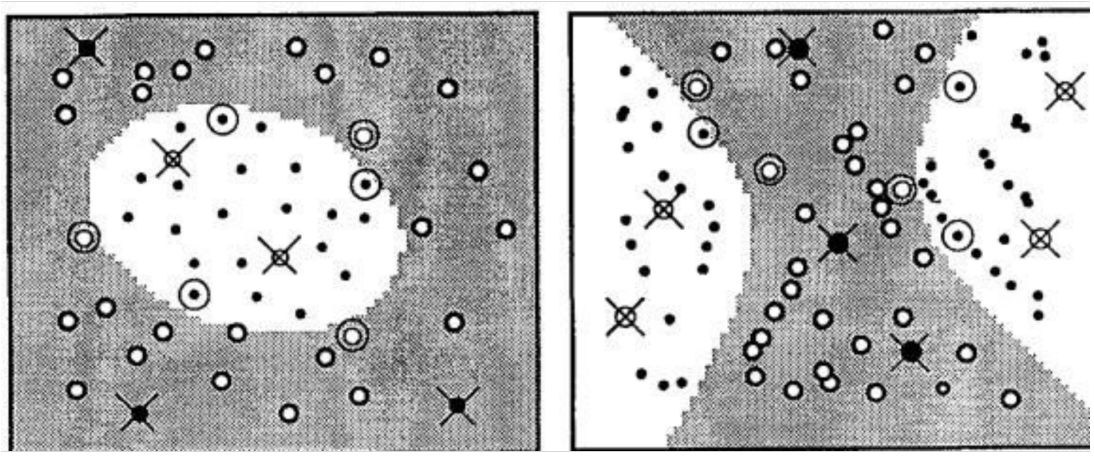


Figura 5 do artigo original: separação por polinômio quadrático ($d = 2$) no plano bidimensional.

VISUALIZAÇÃO 2D

Geometria da fronteira

Com o kernel $K(\mathbf{u}, \mathbf{v}) = (\mathbf{u} \cdot \mathbf{v} + 1)^2$, o classificador sintetiza superfícies curvas no plano original enquanto calcula apenas um hiperplano linear no espaço tridimensional estendido.

Identificação direta: os vetores de suporte (marcados com círculos na figura) tocam as fronteiras da margem curva e os poucos erros de treino são tolerados pelas folgas ξ_i .

RECONHECIMENTO DE DÍGITOS: O PROBLEMA EXPERIMENTAL

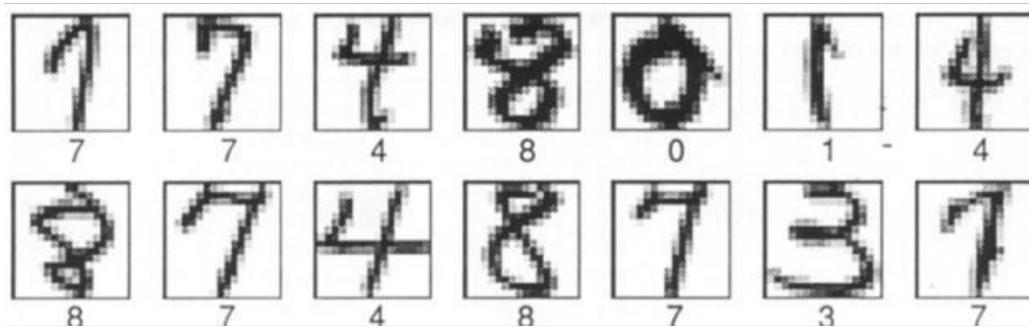


Figura do artigo original: dígitos manuscritos padronizados em escala de cinza.

Base USPS

7.300 padrões de treino, 2.000 de teste; resolução de 16×16 pixels ($n = 256$ dimensões).

Base NIST

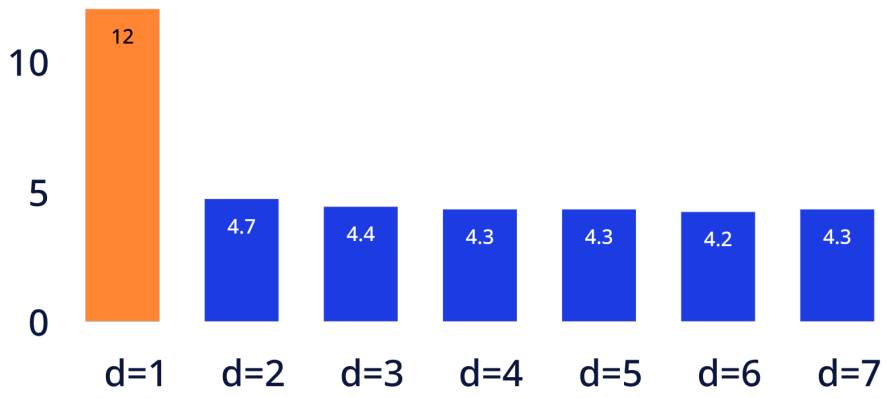
60.000 padrões de treino, 10.000 de teste; resolução de 28×28 pixels ($n = 784$ dimensões).

Estratégia One-vs-All

Dez classificadores binários independentes (um dígito versus todos os demais); decisão final por pontuação máxima de margem.

Inatel

O EFEITO DO GRAU POLINOMIAL



Erro bruto (%) no conjunto de teste USPS.

Grau	Vetores de suporte	Dimensão do espaço
1	200	256
2	127	~33000
3	148	~1×10^6
4	165	~1×10^9
5	175	~1×10^12
6	185	~1×10^14
7	190	~1×10^16

O erro despenca de 12,0% (linear) para 4,7% com grau 2, e depois estabiliza entre 4,2% e 4,4% até o grau 7.

Inatel

O RESULTADO MAIS INSTRUTIVO: DIMENSÃO CRESCE, ERRO QUASE NÃO

PARADOXO DA DIMENSIONALIDADE

Do grau 3 ao grau 7

A dimensionalidade do espaço de características cresce em **dez ordens de magnitude**:

$$d = 3 \implies \dim \approx 10^{6}$$

$$d = 5 \implies \dim \approx 10^{12}$$

$$d = 7 \implies \dim \approx 10^{16}$$

Sob o dogma do aprendizado estatístico clássico, uma explosão de parâmetros dessa ordem deveria provocar sobreajuste severo.

A EVIDÊNCIA EXPERIMENTAL

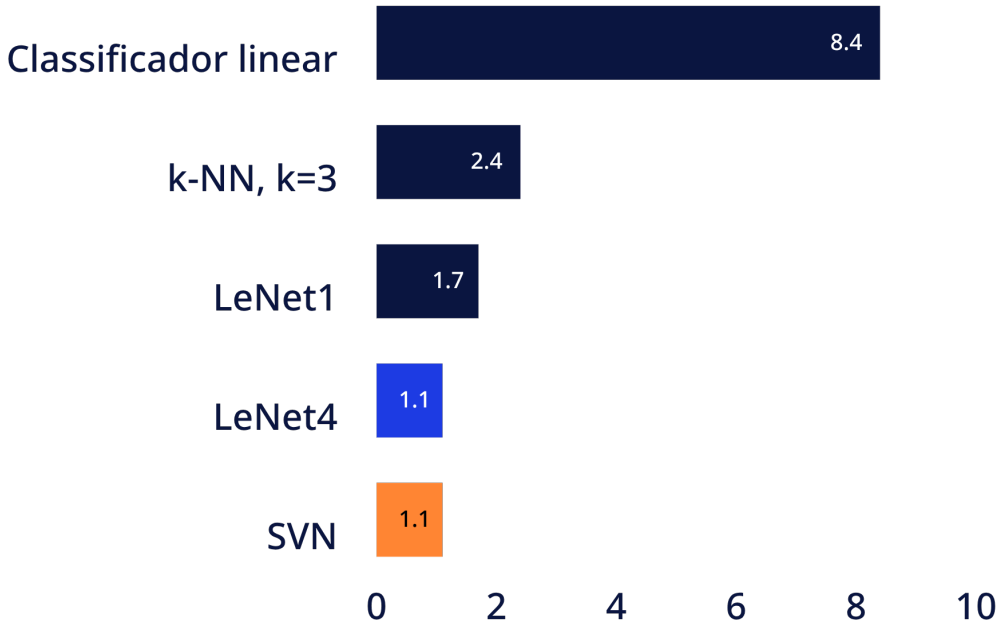
Imunidade ao sobreajuste

O número de vetores de suporte cresce em ritmo extremamente lento (de 148 no grau 3 para apenas 190 no grau 7).

O erro em dados de teste não vistos permanece rigidamente confinado em 4,2% - 4,4%.

A tese de Vapnik confirmada: a capacidade do classificador é governada pela norma $\|\mathbf{w}\|$ e pela margem geométrica, não pela dimensionalidade do espaço de imersão.

BENCHMARK NIST: PRECISÃO COMPETITIVA E LEITURA CRÍTICA



Comparativo histórico de erro de teste (%) na base de dígitos NIST (Cortes e Vapnik, 1995).

1,1%

Paridade com redes convolucionais

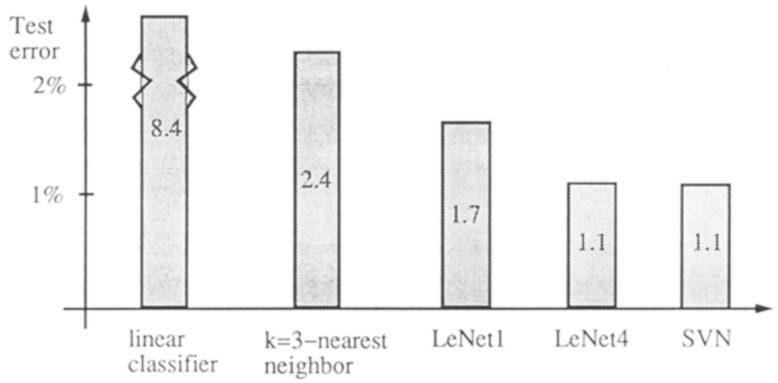
A SVN empata rigorosamente com a LeNet4 (1,1%), o estado da arte convolucional da época nos laboratórios da AT&T Bell Labs.

Leitura Crítica: a comparação é histórica e depende de pré-processamento. O valor duradouro está na formulação: um modelo convexo sem mínimos locais competindo com redes profundas convolucionais ajustadas por backpropagation.

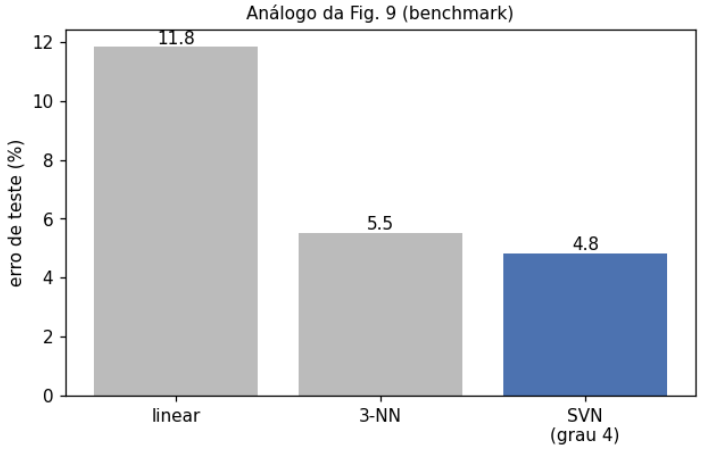
Inatel

REPLICAÇÃO DE EXPERIMENTO

MNIST



ARTIGO

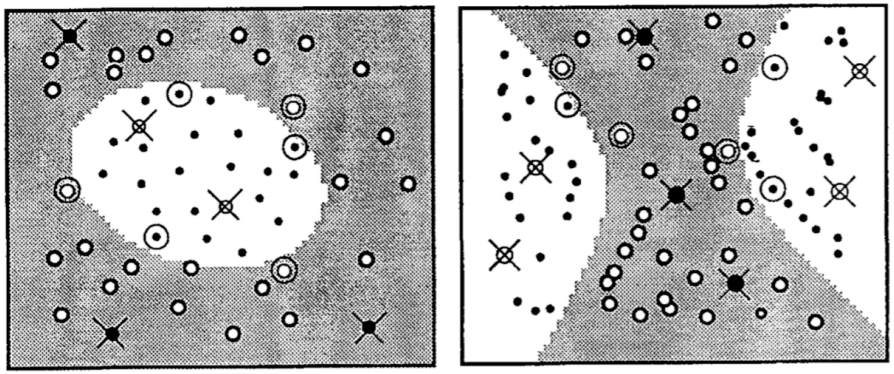


EXPERIMENTO

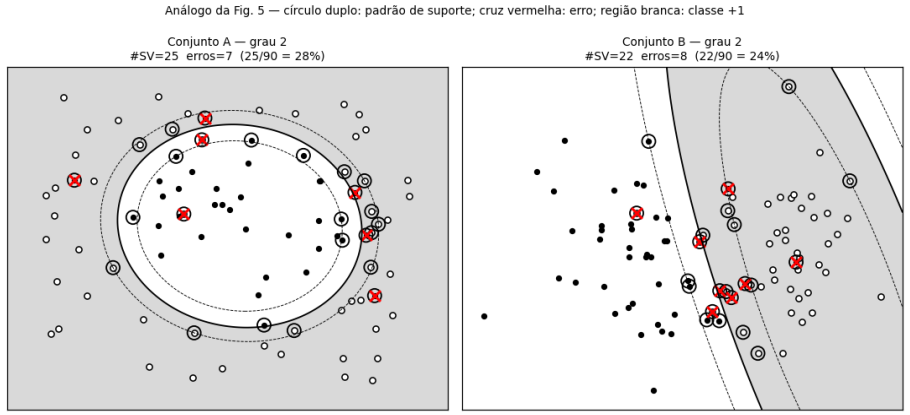
Inatel

REPLICAÇÃO DE EXPERIMENTO

POLINÔMIO GRAU 2



ARTIGO

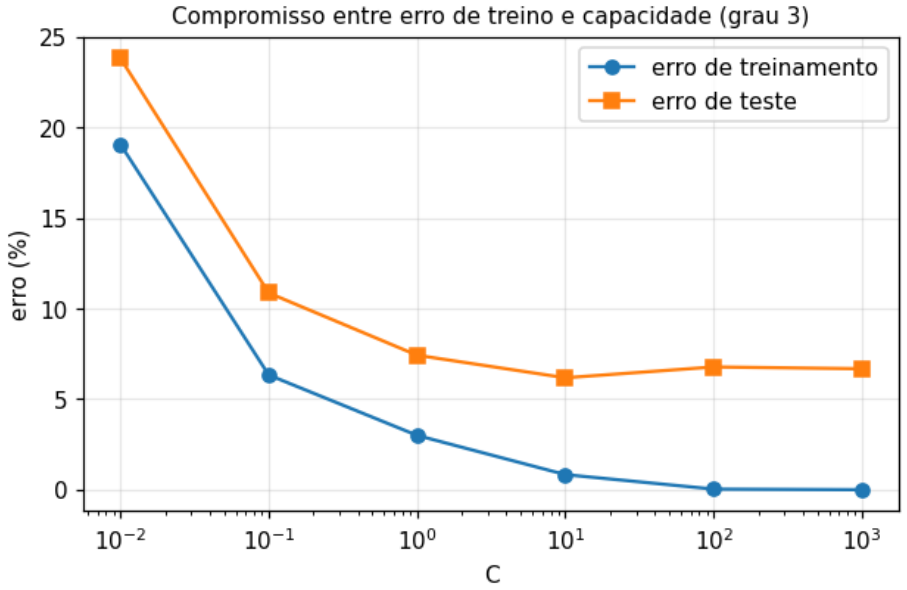


EXPERIMENTO

Inatel

REPLICAÇÃO DE EXPERIMENTO

C



EXPERIMENTO

Inatel

LIMITAÇÕES

- **Dependência da função kernel:** O desempenho depende da função escolhida e dos parâmetros associados. Uma representação inadequada pode não capturar as relações importantes dos dados.
- **Custo de treinamento:** A possibilidade de usar espaços de características muito grandes não significa que o treinamento seja sempre barato. O problema de otimização envolve relações entre exemplos de treinamento, e o custo pode crescer significativamente em conjuntos de dados grandes.
- **Sensibilidade à preparação dos dados:** Nos experimentos USPS, centralização, correção de inclinação e suavização fazem parte do procedimento. Portanto, os resultados não dependem exclusivamente do classificador.
- **Escopo das experiências:** Os experimentos concentram-se em reconhecimento de dígitos manuscritos e conjuntos artificiais. Eles demonstram o potencial do método, mas não comprovam que a mesma configuração será ideal para todos os domínios.
- **Ausência de garantia de erro zero:** As margens suaves permitem que alguns exemplos sejam classificados incorretamente. O objetivo é encontrar um equilíbrio adequado entre ajuste aos dados e capacidade de generalização, e não eliminar necessariamente todos os erros.



CONCLUSÃO

- Constitui uma abordagem poderosa e flexível para problemas de classificação.
- A proposta combina hiperplanos ótimos, transformação da função de similaridade por kernels e margens suaves. Os experimentos demonstram que essa combinação consegue produzir fronteiras não lineares e alcançar taxas de erro reduzidas em reconhecimento de dígitos manuscritos.
- Capacidade de explorar espaços de características de dimensão extremamente elevada sem que a quantidade de vetores de suporte cresça na mesma proporção.
- Destaca o controle da capacidade do modelo e a possibilidade de alterar a forma da fronteira de decisão por meio da função kernel escolhida.
- A qualidade do classificador depende não apenas de sua capacidade de ajustar os exemplos de treinamento, mas também da geometria da solução e do controle de sua complexidade.



TRÊS IDEIAS PARA LEVAR PARA TELECOMUNICAÇÕES

1. Representação do Sinal

A representação é tão importante quanto o classificador. Extrair parâmetros ortogonais (constelação I/Q, decomposição em subportadoras OFDM) condiciona a separabilidade no espaço de características.

2. Robustez Geométrica

A margem máxima confere tolerância intrínseca a perturbações de ruído aditivo e desvanecimento. Maximizar a margem equivale a maximizar a distância mínima euclidiana entre símbolos de comunicação.

3. Similaridade Física

O kernel permite injetar a física do canal de rádio diretamente na geometria do modelo, incorporando invariâncias de fase e atraso temporal sem depender de aumento artificial de dados.

Inatel

UM PIPELINE SVM PARA SINAIS DE TELECOMUNICAÇÕES

01

1. Extração

Amostragem em I/Q, espectrograma, cumilantes de ordem superior ou coeficientes wavelet.

02

2. Normalização

Controle automático de ganho (AGC), remoção de offset de frequência e padronização escalar.

03

3. Escolha do Kernel

Definição da função K (RBF, polinomial) e calibração de hiperparâmetros (C, σ).

04

4. Resolução Dual

Programação quadrática convexa offline para determinação dos vetores de suporte e α_i.

05

5. Decisão em Tempo Real

Classificação do sinal recebido por produto interno apenas com os vetores de suporte retidos.

Aplicações em Telecom: reconhecimento cego de modulações digitais (BPSK, QAM), detecção de interferência de banda estreita, classificação de estados de dispersão no canal e diagnóstico de falhas em enlaces ópticos.

Inatel

Perguntas?

Referências

[1] Cortes, C.; Vapnik, V. Support-Vector Networks. Machine Learning, v. 20, p. 273–297, 1995. doi:10.1007/BF00994018

[2] https://scikit-learn.org/stable/modules/svm.html

[3] Support Vector Machine: tudo o que você precisa saber - https://youtu.be/ny1iZ5A8ilA

[4] Siamese Neural Networks - https://youtu.be/T9yKyZfxUJg

Obrigado!

Inatel

QUESTIONÁRIO

https://docs.google.com/forms/d/e/1FAIpQLSfXzAMu3H7adp_hWnblJfzjK2-DVQoG3dvmiOVQvkdnXI_Ocg/viewform?usp=header

Inatel